

Санкт-Петербургский государственный университет

КАЗАНЦЕВА Анна Вячеславовна

Выпускная квалификационная работа

***Текстовые квесты как инструмент оценки
способностей больших языковых моделей***

Уровень образования: бакалавриат

Направление *02.03.01 «Математика и компьютерные науки»*

Основная образовательная программа *СВ.5189.2022 «Науки о данных»*

Научный руководитель:
научный сотрудник, Лаборатория
искусственного интеллекта,
математики и компьютерных наук
им. А. А. Маркова,
Николаев Максим Сергеевич

Рецензент:
руководитель центра разработки,
Общество с ограниченной
ответственностью «Центр
искусственного интеллекта МВС»,
Малых Валентин Андреевич

Санкт-Петербург
2026

Оглавление

Введение	4
Цель и задачи	5
1. Актуальность	6
1.1. Текстовые квесты как инструмент	7
1.2. Влияние естественных языков	9
2. Обзор литературы	11
2.1. Новизна подхода	12
3. Набор данных	15
3.1. Квесты	15
3.2. Обработка	16
4. Методология	19
4.1. Опция «шаг назад»	20
4.2. Взаимодействие с моделями	20
4.3. Промпты	22
4.4. Взаимодействие с людьми	24
4.5. Сохраняемые данные	24
5. Эксперименты	27
5.1. Пользовательские эксперименты	27
5.2. Эксперименты с моделями	27
5.3. Выбранные языки	28
5.4. Протестированные модели	28
5.5. Проведённые эксперименты	29
6. Анализ результатов	30
6.1. Отбор пользовательских данных	30
6.2. Дистраивание путей	32
6.3. Метрики	32
6.4. Значения метрик	36
6.5. Выводы	36
6.6. Эмпирические наблюдения	39
Заключение	41
Направления развития	42

Благодарности	43
Литература	44
А. Известные текстовые квесты	47
А.1. Zork I	47
А.2. Клуб романтики	48
А.3. Р. Брайтфилд «Похищены!»	48
В. Графовая структура	49
С. Выбранные квесты	50
С.1. Невозможный Квест (части 1 и 2)	50
С.2. Dungeon and Dragon	51
Д. Граф игры «Невозможный Квест 2»	52
Е. Краткая схема разработанной системы	53
Ф. Структура исходного INI-файла квеста	54
Г. Структура JSON-файлов квеста	55
Г.1. Структура JSON-файла описаний концовок	55
Г.2. Структура основного JSON-файла квеста	55
Н. Системные промпты	57
Н.1. Игровой системный промпт	57
Н.2. Системный промпт суммаризации, версия full	58
Н.3. Системный промпт суммаризации, версия short	59
И. Бот для сбора пользовательских данных	61
Ж. Галлюцинации и ошибки в рассуждениях моделей	62
Ж.1. Ошибка в подсчёте (DeepSeek)	62
Ж.2. Ошибка в рассуждении (DeepSeek)	62
Ж.3. Галлюцинация модели (Mistral chat)	63

Введение

Текстовые квесты — это интерактивные повествования, в которых игрок продвигается по сюжету, делая выборы, влияющие на развитие истории.

Этот жанр начал зарождаться ещё в 1940-х годах в виде книг-игр, позволяющих читателю участвовать в формировании сюжета и перемещаться между страницами или главами в зависимости от принимаемых решений. Подобным образом устроенные компьютерные игры начали появляться в 1970-х и с тех пор не теряют популярности и продолжают развиваться, приобретая различные модификации (прил. А).

Такие интерактивные истории могут служить не только развлечением, но и средством развития навыков логического мышления, повествования, памяти, языковых и коммуникативных способностей, поскольку требуют от игрока анализа ситуации и выбора наиболее целесообразного варианта для дальнейшего развития игровых событий с учётом всего накопленного игрового опыта.

Большие текстовые квесты имеют сложную графовую структуру со множеством связей и переходов между узлами сцен (прил. В). Благодаря этому они могут быть полезным многосоставным инструментом для оценки поведения моделей.

В отличие от «статичных» текстов, они создают особые требования к пониманию и запоминанию контекста, так как каждый выбор влияет на последующий сюжет.

Это делает взаимодействие с интерактивной литературой удобным способом изучения способностей систем искусственного интеллекта, например, больших языковых моделей, включая долговременную память, эффективную суммаризацию, умение решать многошаговые задачи.

Анализ того, как модель ориентируется в ветвящемся сюжете, какие его

элементы она «помнит» спустя множество шагов, как использует полученную ранее информацию и строит стратегию взаимодействия со средой, позволяет оценивать сильные и слабые стороны разных архитектур [1, 2].

Цель и задачи

Цель работы — создать динамический бенчмарк на основе текстовых квестов, в которых требуется достичь всех возможных концовок без избыточных повторов маршрутов, позволяющий оценивать способности модели к управлению и использованию памяти, решению многосоставных нелинейных задач, а также оценить влияние языка взаимодействия на способности модели решать задачи такого рода.

Для достижения цели требовалось решить следующие **задачи**.

1. Изучить существующие исследования в этой области.
2. Разработать требования, которым должен удовлетворять квест, чтобы хорошо отражать уровень способностей модели.
3. Подобрать квест по требованиям (возможно, с дополнительной редактурой).
4. Организовать сбор данных о прохождении квеста людьми.
5. Перевести квест на другой естественный язык.
6. Создать автоматизированную систему, которая позволяет имитировать прохождение квеста моделью через API.
7. Разработать промпты (запросы) для взаимодействия с языковыми моделями.
8. Выработать метрики, отражающие успех прохождения квеста.
9. Получить значения метрик для разных языковых моделей и для людей.
10. Проанализировать результаты и подготовить выводы.

1. Актуальность

Способность языковых моделей работать с длинным контекстом, выполнять его суммаризацию (автоматическое реферирование) и корректно обновлять информацию имеет ключевое значение для практических задач, включая анализ научных публикаций, построение цепочек доказательств, работу с юридическими документами, технической документацией, кодом программ.

Задачи более сложные, чем просто генерация текста, встают перед моделями в самых разных прикладных областях. Современные языковые модели становятся основой для агентов и ИИ-ассистентов, взаимодействующих с внешней средой, планирующих свои действия и принимающих решения на основе предыдущего опыта. Они встраиваются в автономные системы, поведение которых разворачивается во времени и где принятие решений зависит от длинной истории взаимодействий [3, 4].

В подобных приложениях модели функционируют в условиях динамически изменяющейся среды, на которую влияют как действия извне, так и решения агента, причём это влияние может стать явным не сразу. В отличие от стандартных задач, здесь модель должна учитывать историю взаимодействия, поддерживать согласованность решений и адаптироваться к новым условиям.

Долговременная память языковых моделей — способность сохранять и использовать контекст из предыдущих взаимодействий — остаётся недостаточной для многих задач из-за архитектурных ограничений. Например, исследования показали, что эффективность работы веб-агентов снижается при увеличении контекста [5].

Современные бенчмарки показывают, что модели могут испытывать трудности с извлечением релевантной информации из длинной и зашумлённой истории взаимодействий, когда возникает необходимость отделять ненужную информацию и разрешать противоречия [6].

При работе с юридическими или техническими текстами требуется корректно связывать удалённые друг от друга фрагменты информации и поддерживать согласованность выводов на протяжении всего взаимодействия, что остаётся трудной задачей для современных моделей [6, 7].

В связи с этим важно изучать то, как модели «помнят» и «забывают» информацию. Понимание этого помогает разработать механизмы внешней памяти и управления контекстом, стратегии обучения и архитектурные улучшения.

1.1. Текстовые квесты как инструмент

Одним из доступных способов тестирования, которые хорошо отражают особенности динамических сред, являются текстовые квесты [8]. Исследования LLM с использованием интерактивной литературы показывают, что подобные среды объединяют задачи последовательного рассуждения, долгосрочного планирования и построения внутреннего понимания состояния мира [9, 10].

Текстовые квесты естественно включают ветвления и логические цепочки, что ближе к реальным задачам, чем тесты на обычном тексте. В них дальнейшая история зависит от совершаемых игроком действий, присутствуют длинные связи, когда выбор игрока или какие-то данные влияют на игру спустя много ходов, ключевая информация может быть «спрятана» среди бесполезной или вообще не получена из-за неправильно выбранной траектории.

Современные модели испытывают трудности с рассуждениями, которые требуются в текстовых играх [11]. Также исследования показывают, что интерактивные среды необходимы для развития искусственного интеллекта [12].

Таким образом, для успешного продвижения по сюжету текстового квеста требуется помнить предыдущие события, планировать свои действия и учитывать все происходящие изменения. Исследование поведения моделей в подобных условиях помогает оценить несколько важных аспектов, от которых

напрямую зависит успех выполнения задачи. Основные из этих аспектов ниже.

1. *Способность долгосрочного планирования и следования цели.* Это важно, когда требуется не один обособленный ответ, а последовательность согласованных и продуманных действий. В случае неспособности действовать в соответствии с предыдущими шагами, ошибки, совершённые на ранних этапах, будут накапливаться и ухудшать качество будущих решений. Подобные проблемы невозможно выявить на статичных бенчмарках.
2. *Устойчивость к изменению контекста и учёт неопределённости.* В реальных задач информация изначально может быть противоречивой или неполной или становиться такой с течением времени, может частично или полностью обновляться в разных местах в ходе взаимодействия. В связи с этим важно умение модели оперативно реагировать на изменения и корректировать свою стратегию, не опираясь только на изначальные или только текущие данные.
3. *Поведенческие свойства разных моделей:* склонность к ошибкам при агрегации контекста, забывание ключевых данных, излишние повторы действий, уход от цели. Особенно сильно эти эффекты проявляются при длительных взаимодействиях и нехватке длины контекста. Важно понимать, когда и как они возникают, чтобы учитывать это при интегрировании моделей в системы, предназначенные для комплексных задач.

Бенчмарки с использованием квестов оценивают весь набор упомянутых выше свойств: эффективное управление памятью и её использование, долгосрочное планирование и удержание стратегии, адаптация к обновлению среды, устойчивость к накапливаемым ошибкам, а также рассуждение для более качественного результата.

Современные модели обладают сильными «локальными» способностями,

однако результаты на интерактивных бенчмарках показывают, что с устойчивым согласованным агентным поведением бывают большие трудности.

1.2. Влияние естественных языков

Большие языковые модели способны обрабатывать запросы на разных языках. Однако многочисленные исследования показывают, что язык взаимодействия существенно влияет на качество ответов моделей. Это связано как с особенностями обучающих данных, так и с внутренними механизмами представления текста в LLM [13].

Одной из причин является неравномерность распределения языков в обучающих корпусах. Большинство современных моделей обучаются преимущественно на англоязычных данных, вследствие чего английский язык становится своего рода «базовым» пространством внутренних представлений модели. В результате качество выполнения задач, требующих многошагового рассуждения и генерации кода на английском языке часто оказывается выше, чем на более узко представленных языках.

Исследования также показывают, что при переходе к смешанному формату взаимодействия ухудшается понимание контекста. Даже имея высокие результаты в задачах на одном языке, модели существенно деградируют при необходимости одновременно интерпретировать несколько языковых контекстов — например, при использовании неанглийских вставок в англоязычном контексте [14]. При этом влияние оказывается асимметричным: добавление английских фрагментов в другие языки иногда даже улучшает качество ответов, что дополнительно подтверждает доминирующую роль английского языка во внутренних представлениях современных LLM [15].

Язык взаимодействия влияет и на управляемость поведения модели. Работа показывает, что одинаковые инструкции, сформулированные на разных языках, могут приводить к различающимся стратегиям рассуждения и разной

степени следования инструкциям [16].

Таким образом, язык взаимодействия с моделью может оказывать существенное влияние на всех этапах решения сложносоставной задачи.

2. Обзор литературы

Существует несколько исследований, где текстовые квесты, изначально созданные человеком в развлекательных целях, выступают основным инструментом оценки способностей моделей.

1. *StoryBench* [2] — закрытый динамический бенчмарк для оценки долговременной памяти LLM, основанный на интерактивной истории, где модель должна отслеживать ветви сюжетов и делать логические выводы для достижения хорошей концовки.

В этом бенчмарке среда для оценки долговременной памяти и последовательного рассуждения формируется на основе одной интерактивной истории с разветвлённым деревом сюжета и несколькими концовками. *StoryBench* моделирует длительное интерактивное взаимодействие, в котором состояние среды непрерывно изменяется в зависимости от действий агента. Каждое решение модели направляет ход развития истории и влияет на доступные в будущем действия и концовки.

В бенчмарке LLM тестируются в двух режимах:

- с немедленной обратной связью: система сразу сообщает модели о том, что выбранный вариант является ошибочным или ведёт к плохому исходу, и предоставляет возможность его изменить;
- без обратной связи: если модель приходит к неудачной концовке, она должна самостоятельно определить, где была допущена ошибка, вернуться к какой-либо предыдущей точке и изменить траекторию прохождения.

Второй режим наиболее полно показывает то, как модель справляется с хранением и использованием накопленного опыта, динамическим планированием и восстановлением причинно-следственных связей.

2. *TextQuests* [1] — бенчмарк, основанный на 25 классических текстовых квестах компании Infocom.

Бенчмарк оценивает способность LLM работать с текстовыми квестами без внешних инструментов, что позволяет анализировать способности к самостоятельному рассуждению, исследованию среды и управлению большим контекстом, формируемым по длинной истории взаимодействий.

В *TextQuests* используется непрерывная история взаимодействия без агрессивного сокращения контекста. В процессе прохождения в промпте сохраняется вся история действий, контекст становится длинным, и модель должна самостоятельно извлекать из него релевантную информацию.

Несмотря на возможное наличие текстов интерактивной литературы в обучающих данных языковых моделей (например, по некоторым косвенным признакам можно предположить, что в обучающей выборке присутствовали данные игры *Zork I* [11]), эмпирические исследования показывают, что современные LLM демонстрируют низкую эффективность в прохождении больших классических текстовых игр (опять же, таких как *Zork I*), что свидетельствует об ограниченности их агентных и планирующих способностей [11, 17].

В статьях [1, 2, 11] отмечается, что глубокое понимание, удержание контекста и выстраивание долгосрочной стратегии остаётся сложной задачей для LLM, и интерактивные игры являются естественной средой для её оценки, поскольку требуют многократного обращения к предыдущим событиям и корректной агрегации полученной информации.

2.1. Новизна подхода

В постановке задачи в настоящей работе есть три ключевых преимущества перед существующими бенчмарками.

1. Указанные исследования используют квесты с классической постановкой задачи: требуется найти хорошую концовку из одной или нескольких возможных. Оценка модели на таком квесте говорит не только о долгосрочной памяти модели, но и о её способностях рассуждать как человек, проходящий игру, или угадывать правильный выбор, опираясь на обучающие данные. При этом зачастую невозможно понять, что больше повлияло на успех или неудачу.

Формулировка задачи **поиска всех возможных концовок** позволяет уменьшить влияние подражания человеческой интуиции и сместить фокус на способность управлять контекстом и максимально полно исследовать игровое пространство.

Важным требованием является уточнение задачи, что нужно минимизировать количество затраченных прохождений, избегая повторных находений концовок. Это ставит некоторые ограничения на процесс прохождения, поэтому модель должна аккуратно и эффективно выстраивать стратегию, не упуская из внимания никакую важную информацию, полученную из предыдущих прохождений и знаний об открытых концовках.

2. Также существующие работы с использованием текстовых квестов не учитывают **влияние использования разных языков** на эффективность работы LLM. Как было упомянуто ранее, в ряде исследований замечено влияние языка взаимодействия на эффективность работы LLM. Эта работа позволит проверить, может ли изменение языка среды продемонстрировать это явление на комплексной задаче, где требуется нетривиальное управление историей взаимодействий, а также то, как смена естественного языка влияет на накопление знаний и возможность их использования.
3. Наконец, представленная работа позволит провести **сравнение прохождений квеста моделями и людьми** по всем метрикам, увидеть различия и особенности стратегий и оценить, насколько далеки LLM от

людей в подобных задачах и почему.

Данная работа фокусируется на систематическом поиске всех возможных концовок при повторных прохождении и анализе влияния языкового режима на эффективность управления контекстом, что позволяет более комплексно и обширно оценить способности моделей в интерактивных сценариях.

В отличие от существующих бенчмарков, таких как *StoryBench* и *TextQuests*, где основное внимание уделяется поддержанию одной длинной истории взаимодействия или прохождению фиксированного набора интерактивных игр, настоящая работа вводит новую постановку задачи, несколько языковых режимов и сравнение результатов моделей с человеческими.

3. Набор данных

3.1. Квесты

В процессе работы были определены требования, которым должен удовлетворять квест, чтобы наиболее качественно оценивать способности модели:

- есть достаточно длинные связи между узлами, для успешного прохождения нужно помнить информацию, встреченную в игре ранее;
- нет визуальных головоломок и других видов взаимодействий с игрой, только текст;
- большинство разветвлений, ведущих к разным концовкам, находятся за несколько шагов до концовок (не слишком близкое к линейному повествование);
- выборы на развилках могут вести к одной и той же концовке (существуют узлы, не имеющие «смысла»);
- качественное и грамотное написание, увлекательный сюжет (чтобы люди были заинтересованы в прохождении);
- отсутствие случайностей, влияющих на ход развития истории (одна и та же последовательность выборов должна всегда вести к одной и той же сцене или концовке);
- желательно отсутствие доступных в Интернете прохождений и подсказок по игре (так как не исключена возможность положительного влияния попадания подобной информации в обучающие данные на результат игры).

Были выбраны несколько подходящих квестов прил. С:

1. *Невозможный Квест* [18] — квест, в исходном виде удовлетворяющий большинству требований, исходные файлы с описанием графа квеста недоступны;
2. *Невозможный Квест 2* [19] — аналогичный квест от того же автора с доступными исходными файлами (30 концовок и 179 сцен выбора, среднее время полного прохождения — нахождения всех концовок — человеком составляет около часа);
3. *Dungeon and Dragon* [20] — мини-квест от того же автора (7 концовок и 31 сцена выбора, полное прохождение — нахождение всех концовок — человеком занимает 10-15 минут).

Для использования первого квеста ввиду отсутствия удобных материалов потребовалось бы вручную составить граф квеста, поэтому решено было взять второй квест — *Невозможный Квест 2*.

На момент проведения исследований дополнительное преимущество второго квеста в сравнении с первым в том, что как самого квеста, так и прохождений и подсказок по нему нет в открытых текстовых источниках.

Третий мини-квест *Dungeon and Dragon* использовался для отладки систем.¹

3.2. Обработка

Исходный файл с графом квеста претерпел некоторые изменения по двум причинам: неполное соответствие сформулированным требованиям и неудобный для дальнейшей работы формат (прил. F). Была выполнена следующая обработка (выполнялась вручную, если не указано иного):

- мини-игры, в которых можно проиграть или выиграть, и это повлияет на дальнейший сюжет, заменены на выборы вида «справиться»/«не справиться», что сохраняет игровую механику;
- добавлено несколько новых сцен «технического» назначения, дубли-

¹Было получено разрешение автора на использование всех игр.

рующих основные сцены, но не меняющих структуру квеста, чтобы переходы по графу больше не зависели от внутренних переменных;

- текст просмотрен на предмет ошибок в орфографии, пунктуации, грамматике, стилистике, отредактирован без изменения смысла;
- реализован автоматический парсинг квеста — все сцены и переходы подготовлены в файле формата JSON, содержащем для каждого элемента его идентификационный номер, тип, а также:
 - для каждой сцены: текст и идентификатор соответствующего ей узла выбора;
 - для каждого узла выбора: список опций, для каждой из которых — порядковый номер опции внутри узла, текст опции и идентификатор сцены или концовки, к которой она ведёт;
 - для каждой концовки: порядковый номер концовки и её текст;
- для мини-квеста повествование автоматически объединено в блоки, каждый из которых заканчивается выбором и требует ответа модели (для основного квеста это выполнено изначально);
- в некоторые сцены добавлены чекпойнты (номер и название): в основной квест — 6 чекпойнтов (включая начало квеста), расположенных так же, как в самой игре, в мини-квест — в сцены глобальных сюжетных разветвлений;
- интегрирован автоматический перевод всех текстовых полей JSON-файла с исходного русского на английский язык с помощью Mistral Large 3 [21];
- проверена корректность перевода и внесены правки в местах, где перевод был неточным из-за недостатка контекста или непереводаемой игры слов (после вычитки возможное влияние на прохождение квеста той же моделью, с помощью которой выполнялся перевод, становится минимальным);

- для файла с краткими описаниями концовок, который нужен для формирования списка открытых концовок, было сделано всё то же самое (редактура, парсинг, перевод).

Форматы полученных файлов приведены в прил. G.

Решение добавить чекпойнты было принято после проведения тестовых пользовательских экспериментов. Поскольку в изначальном варианте после достижения некоторой концовки требовалось проходить всё заново с самого начала, это занимало гораздо больше времени, и немногие согласились бы пройти квест полностью.

Для справедливого исследования чекпойнты были добавлены и в эксперименты с моделями. Для корректного анализа результатов позже пути в прохождении, начавшихся с чекпойнта, были «достроены» определённым образом, одинаково для людей и моделей.

В самой игре чекпойнты имеют линейное расположение (начав с чекпойнта с номером i нельзя встретить чекпойнт $j \geq i + 2$, не встретив чекпойнты с номерами $i + 1, \dots, j - 1$). Таким образом, каждая концовка может быть отнесена к конкретному чекпойнту — тому, из которого можно в неё добраться за наименьшее число шагов.

Распределение концовок по чекпойнтам неравномерное (чекпойнты содержат от 1 до 8 концовок), и из совокупности этих факторов граф квеста получается равномерно растущим «в глубину» и «в ширину».

Это даёт и другие преимущества: в зависимости от набора открытых концовок и встретившихся на пути от чекпойнта к концовке развилок можно понять, на каких чекпойнтах нужно искать неоткрытые концовки, а на каких их точно нет. С учётом этого можно будет увидеть, смогла ли модель сделать верные выводы.

Итоговая графовая структура выбранного квеста приведена в прил. D.

4. Методология

Для проведения экспериментов были созданы две системы: для взаимодействия с моделями и для взаимодействия с людьми.

Общая структура всего проекта приведена в прил. Е и на рис. 4.1.




Рис. 4.1.: Краткая схема разработанной системы

4.1. Опция «шаг назад»

Наряду с вариантами выбора в узлах система предоставляет возможность сделать «шаг назад» — вернуться в предыдущую сцену пройденного пути. Пользоваться этой опцией можно неограниченное количество раз, нельзя вернуться назад только в той сцене, с которой начиналось текущее прохождение.

Возможность «отменять» последний выбор играет ключевое значение при текущей постановке задачи — открыть все концовки за как можно меньшее число прохождений. Если игрок (модель или человек) осознаёт, что вскоре будет повторно открыта уже встреченная концовка, эта опция позволяет не приходить вынужденно в уже опробованный вариант, а попытаться достичь новой концовки на текущей попытке прохождения.

Использование «шага назад» отражает построение и следование стратегии, а также уровень осознания связей концовок со сделанными выборами и встреченными сценами.

4.2. Взаимодействие с моделями

Поскольку возможность тестировать «истинную» память модели через API, продолжая взаимодействие в рамках диалога с сохранением всей предыдущей истории, доступна не для всех исследуемых моделей, были реализованы два режима работы.

Наличие двух режимов для некоторых моделей позволит проверить, насколько сопоставимы использование внешней и внутренней контекстной памяти.

В режиме диалога (**chat**) используется нативная память модели, этот режим доступен, если API позволяет поддерживать непрерывный диалог. В стандартном режиме (**concat**) память имитируется: сами запросы являются независимыми, а история взаимодействия сохраняется локально и при каждом новом запросе передаётся модели вместе с текущим контекстом либо

целиком, либо в виде агрегированного самой моделью резюме.

1. Стандартный режим `concat` (без сохранения истории взаимодействий напрямую моделью):

- *игровой системный промпт*: описание задачи игры, информация об игровой механике и получаемых данных, правила ввода ответа;
- *игровой процесс*: в процессе игры модель получает саммари предыдущих прохождений, историю текущего прохождения (если есть), текущую сцену (или список доступных чекпойнтов, если это начало нового прохождения) и варианты выбора;
- *системный промпт суммаризации*: описание задачи игры, информация о получаемых данных, правила ввода, а также:
 - в версии `full` (упор на конкретный способ суммаризации) — советы, что нужно и что не нужно сохранять;
 - в версии `short` (возможность модели самой выбрать способ суммаризации) — более подробная информация о правилах самой игры;
- *обновление саммари*: после совершения выбора, ведущего к концовке, модель получает саммари предыдущих прохождений, полную историю последнего прохождения и список всех открытых концовок с краткими описаниями.

2. Режим диалога `chat` (история взаимодействий доступна и агрегируется моделью):

- *игровой системный промпт*: описание задачи игры, информация об игровой механике и получаемых данных, правила ввода ответа;
- *игровой процесс*: в процессе игры модель получает только текущую сцену и варианты выбора; если текущая сцена — концовка, модель получает её, список открытых концовок с краткими описаниями,

список доступных чекпойнтов и варианты выбора;

- *в случае ошибочного ввода*: модель получает сообщение об ошибке ввода и полный повтор предыдущего промпта.

Система включает следующие компоненты: (a) хранилище данных; (b) адаптеры для API разных моделей; (c) непосредственно механизм выдачи текста и обработки ответов модели.

4.3. Промпты

Игровой системный промпт и пользовательский промпт опираются на инструкции и информацию, получаемые людьми в процессе игры, и состояются аналогично им. Системные промпты суммаризации подбирались вручную итеративно по результатам нескольких тестовых прогонов с различными моделями с целью устранения ошибок в формате ответа.

В результате были выбраны устойчивые варианты промптов, обеспечивающие корректное поведение моделей в большинстве сценариев. Промпты не оптимизировались под конкретные модели и не подбирались индивидуально для улучшения метрик. Влияние вариаций формулировок, если и присутствует, оценивается как несущественное.

1. *Игровой системный промпт.*

Здесь описана цель игры, получаемые данные, подробно и строго указаны правила ввода ответа (исключительно число, соответствующее номеру выбранной опции, номер должен быть строго из предоставленных вариантов), игровая механика, описана опция шаг назад и цель её применения.

Промпт основан на информации, которая даётся людям перед началом квеста, с учётом общих особенностей взаимодействия с LLM.

2. *Системный промпт суммаризации, версия full.*

Здесь описано, что следует сохранять (открытые концовки, важные факты, совершённые выборы, разработанные стратегии, информацию о ветках, связь концовок с чекпойнтами) и что следует удалять (повторяющуюся и бесполезную информацию, излишние пояснения, ненужные рассуждения, очевидные выборы), совет обновлять данные и создавать структурированное, согласованное, понятное саммари, при необходимости сохраняя части прохождений без изменений.

3. Системный промпт суммаризации, версия *short*.

Здесь более подробно описана игровая механика (подобно игровому системному промпту) и кратко указано, что нужно обновить саммари, без детальных инструкций о том, как это делать, с указанием, что игрок получит это саммари для продолжения игры. Этот промпт даёт модели возможность определить свой способ управления памятью и реализовать его без скрытого подталкивания к какому-то определённому со стороны системы.

4. Пользовательский промпт.

Здесь, помимо текущего саммари, обязательно указывается полная история текущего прохождения со всеми сделанными выборами (в том числе с шагами назад) и всеми посещёнными сценами (в хронологическом порядке, после каждого выбора).

Если очередное прохождение ещё не начато, то после саммари идёт список чекпойнтов.

Если текущее прохождение окончено, то этот промпт отправляется на суммаризацию и содержит, помимо саммари и полного текущего прохождения, список всех концовок (с нумерацией и указанием, открыта ли каждая, у открытых концовок дано краткое описание).

Все системные промпты сформулированы на английском языке. Инструкции и опция «шаг назад» в пользовательском промпте отправляются также на английском языке, а содержание пользовательского промпта (сцены, варианты

выборов, описание концовок) — на языке соответствующего запуска.

Полное содержание промптов приведено в прил. Н.

4.4. Взаимодействие с людьми

Можно считать, что взаимодействие с людьми проходит так же, как с моделями в режиме диалога. Условия максимально уравниены с точки зрения структуры входных данных и доступных действий, что обеспечивает сопоставимость результатов.

Для сбора данных о человеческих прохождениях был создан бот в Telegram [22,23]. В информации о боте указано, что собранные данные будут использоваться в исследовательских целях.

В боте приём ответов реализован посредством кнопок, опции на которых совпадают с вариантами выбора в текущей сцене (во избежание неправильного формата ввода ответа), а для имитации «использования исключительно памяти» сообщение со сценой исчезает сразу после совершения выбора.

Список открытых концовок можно посмотреть только в перерывах между прохождениями, прервать текущее прохождение нельзя, можно только закончить, дойдя до концовки. Задача и все правила прохождения квеста указаны в приветственном сообщении.

Данные собираются обезличенно. Перед началом квеста каждый пользователь отвечает на несколько вопросов анкеты с вариантами ответов (табл. 4.1).

4.5. Сохраняемые данные

Информация обо всех играх сохраняется в одинаковом формате и обновляется в процессе всей игры. В JSON игры находится следующая информация (табл. 4.2).

Таблица 4.1.: Собираемые через анкету данные участников

Параметр	Варианты ответа
Пол	мужской; женский
Возраст	до 12; 13–17; 18–24; 25–35; 35–50; 50+
Уровень образования	4 класса; 9 классов; 11 классов; колледж; бакалавриат; магистратура/специалитет; аспирантура
Учится ли в данный момент	да; нет
Работает ли в данный момент	да; нет
Играл ли в текстовые квесты ранее	да; нет

Таблица 4.2.: Сохраняемые данные о запусках

Для всех	
Номер текущего прохождения Информация о текущем прохождении* Информация обо всех завершённых прохождениях* Количество посещений каждой концовки Полная история посещений концовок в хронологическом порядке Открытые на данный момент чекпойнты	
Для моделей	Для пользователей
Параметры запуска Ошибки ввода (неверный формат или недопустимый выбор) Полная история игры (все промпты и ответы без ошибок ввода) Полная история текущего прохождения Текущее саммари (в режиме concat) Список всех сделанных саммари (в режиме concat)	Анкетные данные
* Информация о прохождении	
Номер прохождения Концовка (для завершённых прохождений) «Итоговый» список посещённых сцен без повторов («шаг назад» стирает последнюю сцену) Полный список номеров совершённых выборов Полный список посещённых сцен («шаг назад» дописывает предыдущую сцену)	

5. Эксперименты

5.1. Пользовательские эксперименты

На момент написания работы бота посетило 114 пользователей, 22 из которых полностью завершили прохождение (открыли все концовки).

Всем, кроме одного человека, понадобилось менее 90 прохождений. Более чем 80% из них потребовалось менее 60 прохождений.

Всем, кроме одного человека, понадобилось менее 1500 итераций взаимодействия. 68% людей потребовалось менее 1000 итераций взаимодействия (циклов «запрос–ответ»).

5.2. Эксперименты с моделями

Ограничения по количеству прохождений и итераций для моделей были выбраны исходя из необходимого людям для завершения игры количества. С опорой на данные пользователей, полностью прошедших игру, для моделей в экспериментах были выбраны ограничения сверху: 90 прохождений и 3000 итераций взаимодействия.

Поскольку приведённая статистика рассчитана на подвыборке пользователей, успешно завершивших квест, пороги для моделей были выбраны с запасом. Такое расширение верхней границы по сравнению с наблюдаемыми значениями у людей позволяет не ограничивать стратегии моделей и избежать искусственного отсечения более длинных траекторий решения при сохранении сопоставимости условий эксперимента.

В каждом запуске выбирается модель, режим (стандартный или диалог), язык (русский или английский) и, в случае выбора стандартного режима, версия системного промпта суммаризации (full или short). Режим диалога может быть выбран, только если API позволяет сохранять доступ к диалогу.

5.3. Выбранные языки

Эксперименты с моделями проводились на двух языках: русском и английском.

При этом в запусках с английским языком все промпты были полностью на английском, а в запусках с русским — «служебная» информация и системные промпты оставались на английском языке, а основное содержание пользовательских промптов — на русском.

Таким образом, проведённые эксперименты позволяют проверить, имеет ли место в данной задаче проявление описываемого в литературе снижения эффективности моделей при необходимости одновременно обрабатывать несколько языковых контекстов (в данном случае при использовании русскоязычного контента с ключевой информацией с англоязычными инструкциями).

5.4. Протестированные модели

Были выбраны и протестированы следующие модели (табл. 5.1). Тестирование в режиме диалога через API доступно только у Mistral Large 3.

Таблица 5.1.: Протестированные модели

Модель	Разработчик	Дата релиза	Размер контекст-ного окна
Mistral Large 3 [21]	Mistral AI	02.12.2025	256k
Mistral Large 3 [21] (режим диалога)	Mistral AI	02.12.2025	256k
DeepSeek-V4-Pro [24]	DeepSeek	24.04.2026	1M
Claude Haiku 4.5 [25]	Anthropic	15.10.2025	200k
Claude Sonnet 4.6 [26]	Anthropic	17.02.2026	200k

5.5. Проведённые эксперименты

Параметры: модель (model), режим (mode), язык (lang), версия системного промпта суммаризации (summ. type), максимальное число токенов для суммаризации (max tokens), количество запусков (launch count).

Температура (temp) везде выставлялась равной 0 для снижения случайности выбора.

Список проведённых экспериментов представлен в табл. 5.2.

Таблица 5.2.: Проведённые эксперименты

model	mode	lang	summ. type	max tokens	launch count
Mistral Large 3	concat	ru	full	30000	3
Mistral Large 3	concat	ru	short	30000	2
Mistral Large 3	concat	en	full	30000	3
Mistral Large 3	concat	en	short	30000	3
Mistral Large 3	chat	ru	—	—	3
Mistral Large 3	chat	en	—	—	3
DeepSeek-V4-Pro	concat	ru	full	30000	3
DeepSeek-V4-Pro	concat	ru	short	30000	2
DeepSeek-V4-Pro	concat	en	full	30000	3
DeepSeek-V4-Pro	concat	en	short	30000	2
Claude Haiku 4.5	concat	ru	full	30000	3
Claude Haiku 4.5	concat	en	full	30000	3
Claude Sonnet 4.6	concat	ru	full	30000	1

Для модели Claude Sonnet 4.6 был выполнен только один запуск ввиду высокой стоимости проведения экспериментов.

Все итоговые эксперименты проводились в мае 2026 года.

6. Анализ результатов

Отбор пользователей, построение путей и подсчёт метрик по файлу единого формата с информацией об игре пользователя/модели были автоматизированы.

6.1. Отбор пользовательских данных

Многие пользователи начинали играть, но останавливались после нескольких прохождений, не найдя все концовки. Учёт результатов таких людей дал бы существенное смещение, поскольку поведение участников, завершивших прохождение квеста, и участников, потерявших интерес до выполнения игровой задачи, существенно различается.

Потому из пользователей в рассмотрение были взяты люди, открывшие все концовки, а также нашедшие не менее 90% концовок (то есть не менее 27 из 30) или совершившие не менее 90 попыток прохождения (у таких людей были взяты только первые 90 прохождений для сопоставимости результатов с результатами моделей, которым было дано только 90 попыток). Таким образом, были проанализированы данные 27 пользователей.

Критерий отбора участников намеренно включает не только пользователей, полностью открывших все концовки или совершивших много прохождений, но и пользователей, близких к завершению квеста. Такое расширение выборки позволяет снизить смещение и получить более устойчивую оценку человеческого поведения в задаче.

Распределение 27 отобранных пользователей по социально-демографическим характеристикам и наличию опыта игры в текстовые квесты следующее (табл. 6.1).

Высока доля пользователей мужского пола и молодых участников. Подобное смещение достаточно типично для добровольных выборок в цифровых

Таблица 6.1.: Распределение пользователей

Параметр	Категория	Доля
Пол	Мужской	0,73
	Женский	0,27
Возраст	18–24	0,81
	25–35	0,12
	36–50	0,08
Уровень образования	11 классов	0,31
	Бакалавриат	0,46
	Магистратура/специалитет	0,15
	Аспирантура	0,08
Учится ли в данный момент	Да	0,77
	Нет	0,23
Работает ли в данный момент	Да	0,65
	Нет	0,35
Играл ли в текстовые квесты ранее	Да	0,65
	Нет	0,35

экспериментах, связанных с игровыми сценариями. Заметно ожидаемое смещение в сторону уже игравших в текстовые квесты пользователей, так как участие в исследовании предполагает интерес к подобным интерактивным форматам, что естественным образом повышает вероятность наличия релевантного опыта.

Однако эти смещения не влияют на корректность сравнения моделей и людей, поскольку анализируется не общая картина того, как люди в среднем проходят текстовые квесты, а поведенческие стратегии участников, успешно выполняющих одинаково заданную задачу в фиксированных условиях.

6.2. Достраивание путей

Для честного сравнения и подсчёта некоторых метрик реализовано «достраивание» путей от начала квеста в прохождениях, начавшихся с чекпойнта: последний из кратчайших среди открытых этим игроком (пользователем или моделью) на момент начала текущего прохождения путь от начала квеста до этого чекпойнта.

6.3. Метрики

Обозначения в рамках одного запуска:

- *Endings* — множество всех концовок,
- $Depth(E)$ — глубина концовки (количество рёбер на минимальном пути до неё от начала квеста),
- *Opened* — множество открытых концовок,
- $Count(E)$ — количество открытий концовки E ,
- *Runs* — все завершённые прохождения,
- $Len(R)$ — длина итогового прохождения без шагов назад (количество рёбер),

- $FullLen(R)$ — длина полного прохода с учётом шагов назад (количество рёбер),
- $Back(R)$ — количество шагов назад в прохождении R ,
- $BackChains$ — множество всех непрерывных последовательностей шагов назад.

Метрики:

1. $RunCounter$ — количество совершённых проходов.

$$RunCounter = |Runs|$$

2. $StepsCounter$ — общее количество совершённых действий.

$$StepsCounter = (|Runs| - 1) + \sum_{R \in Runs} FullLen(R)$$

3. $UniqueEndings$ — доля уникальных открытых концовок.

$$UniqueEndings = \frac{|Opened|}{|Endings|}$$

Основная метрика, итоговая эффективность.

4. $BadRuns$ — доля проходов, не приведших к новой концовке.

$$BadRuns = \frac{|Runs| - |Opened|}{|Runs|}$$

Показывает эффективность планирования и умение видеть причинно-следственные связи.

5. $RepeatEndings$ — среднее количество посещений открытых концовок.

$$RepeatEndings = \frac{1}{|Opened|} \sum_{E \in Opened} Count(E)$$

Показывает, как хорошо игрок помнит пути, ведущие к открытым концовкам.

6. *AverageDepth* — средняя глубина всех открытых концовок относительно общей средней глубины.

$$TotalAverageDepth = \frac{1}{|Endings|} \sum_{E \in Endings} Depth(E)$$

$$AverageDepth = \frac{\frac{1}{|Opened|} \sum_{E \in Opened} Depth(E)}{TotalAverageDepth}$$

Склонность к исследованию более далёких или более близких концовок.

7. *TotalBack* — доля шагов назад из всех выборов.

$$TotalBack = \frac{\sum_{R \in Runs} Back(R)}{\sum_{R \in Runs} FullLen(R)}$$

Показывает интенсивность использования механизма возврата.

8. *AverageBackLength* — средняя длина цепочек из шагов назад.

$$AverageBackLength = \frac{1}{|BackChains|} \sum_{c \in BackChains} Len(c)$$

Показывает, насколько глубоко игрок в среднем откатывается по дереву решений.

9. *RedundantBacks* — доля «бесполезных» шагов назад (после которых идёт выбор не назад, повторяющий уже опробованный на этом прохождении выбор) среди всех шагов назад, после которых идёт выбор не назад.

ValidBacks — количество шагов назад, после которых был сделан некоторый выбор, отличный от шага назад.

UselessBacks — количество таких шагов назад, после которых был повторён уже сделанный ранее в данной сцене выбор, отличный от шага назад.

$$RedundantBacks = \frac{UselessBacks}{ValidBacks}$$

Показывает, насколько часто возврат не приводил к исследованию новой альтернативы.

10. *IterationN* ($N = 20, 27, 28, 29, 30$) — номер прохождения, на котором впервые мощность множества открытых концовок стала равна N .

Абсолютная «скорость» исследования.

Все метрики усредняются по всем запускам для каждого режима каждой модели.

Метрика *IterationN* усреднялась только по тем экспериментам, где хотя бы N концовок были найдены.

Важно понимать, что в случаях, когда не во всех запусках одного эксперимента сделано 90 прохождений, усреднение некоторых метрик (*BadRuns*, *RepeatEndings*) может быть смещено из-за разного вклада отдельных запусков. Однако в экспериментах, где все запуски «полные» (имеют 90 завершённых прохождений), указанные метрики сохраняют корректную интерпретацию и сопоставимость между экспериментами.

6.4. Значения метрик

Результаты представлены в табл. 6.2.

Модель Claude Haiku 4.5 исключена из рассмотрения по причине заикливания с неверным форматом ввода на ранних этапах во всех экспериментах.

6.5. Выводы

1. Несмотря на то, что выполнить компактное резюме пройденной части квеста и систематически обновлять его после каждого нового прохождения возможно для человека, суммаризация даже с чёткими инструкциями по сохранению структуры показывает заметное снижение эффективности по сравнению с внутренней агрегацией контекста моделью, как это происходит в режиме диалога.

Это видно из сильно разнящихся результатов модели Mistral в режимах chat и concat.

2. Влияние языка неоднородно и зависит от модели и режима. Устойчивого значимого преимущества английского языка перед русским в пределах протестированной пары высокоресурсных языков не наблюдается.

Для DeepSeek с промптом “full” и Mistral в режиме concat оно совсем небольшое, для DeepSeek с промптом “short” оно и вовсе отсутствует.

У Mistral в режиме диалога русский язык даёт более высокие результаты, что может быть эффектом малого числа запусков.

В целом наблюдения, связанные с разными языковыми режимами, подтверждают гипотезу о том, что русский язык тоже достаточно хорошо представлен в обучающих данных моделей. Более надёжно ранее указанный эффект может быть оценен при сравнении с малоресурсными языками.

3. Результаты с short-версией промпта суммаризации у большинства

Таблица 6.2.: Результаты экспериментов

model	mode	lang	summ. type	Run Counter	Steps Counter	Unique Endings, Runs, доля ↑	Bad Endings, Runs, доля ↓	Repeat Endings ↓	Average Depth, доля	Total Back, доля	Average Back Length	Redundant Backs, доля	Iteration 20 ↓	Iteration 27 ↓	Iteration 28 ↓	Iteration 29 ↓	Iteration 30 ↓
Claude Sonnet 4.6	concat	ru	full	90,00	1156,00	0,63	0,79	4,74	1,01	0,02	1,35	0,53	—	—	—	—	—
DeepSeek-V4-Pro	concat	en	short	90,00	2027,50	0,90	0,70	3,34	0,91	0,27	1,67	0,63	42,50	44,00	48,00	—	—
DeepSeek-V4-Pro	concat	en	full	76,67	2269,33	0,92	0,62	2,76	0,89	0,26	1,75	0,68	28,00	46,00	62,50	—	—
DeepSeek-V4-Pro	concat	ru	short	90,00	1702,50	0,92	0,69	3,27	0,91	0,13	1,58	0,55	30,00	61,50	58,00	—	—
DeepSeek-V4-Pro	concat	ru	full	67,00	2711,67	0,78	0,63	2,80	0,69	0,30	1,66	0,72	23,00	35,00	52,00	—	—
Mistral Large 3	chat	en	—	56,67	1390,67	0,79	0,52	2,34	1,00	0,09	1,63	0,57	24,00	89,00	—	—	—
Mistral Large 3	chat	ru	—	90,00	1845,33	0,87	0,71	3,48	1,05	0,02	1,14	0,60	22,00	58,00	87,00	—	—
Mistral Large 3	concat	en	short	62,00	586,00	0,23	0,66	8,02	0,33	0,03	1,45	0,69	—	—	—	—	—
Mistral Large 3	concat	en	full	90,00	1138,00	0,21	0,93	15,83	0,28	0,00	1,02	0,20	—	—	—	—	—
Mistral Large 3	concat	ru	short	90,00	573,00	0,15	0,95	22,50	0,39	—	—	—	—	—	—	—	—
Mistral Large 3	concat	ru	full	63,67	372,67	0,11	0,83	25,73	0,56	0,01	1,25	0,75	—	—	—	—	—
users	chat	ru	—	54,26	917,04	0,99	0,42	1,92	0,99	0,07	1,91	0,20	29,19	40,92	43,54	46,52	53,43

моделей и режимов оказываются немного выше, чем с “full”-версией.

Это может свидетельствовать о том, что более свободный формат резюме не ухудшает качество сохранения информации, а в ряде случаев оказывается более предпочтительным.

При этом лучший результат среди моделей был достигнут DeepSeek в режиме concat на английском языке как с “full”-, так и с “short”- версией промпта.

4. Результаты Mistral в режиме concat очень низкими с любым промптом суммаризации на обоих языках, в отличие от режима chat, который близок по качеству к лучшему среди моделей результату. Для этой модели данный способ сохранения накопленной информации оказывается менее эффективным, чем использование полной истории диалога.
5. Человеческие результаты значительно превосходят результаты всех протестированных моделей по совокупности метрик. Люди открывают больше концовок, используют меньшее число проходов, реже делают «бессмысленные» шаги назад и в среднем возвращаются назад дальше, о чём говорит метрика *AverageBackLength*.

Однако некоторые модели (DeepSeek и Mistral в режиме chat) в некоторых запусках сначала открывают концовки «быстрее» людей (вплоть до нахождения 27 концовок), но затем не могут найти оставшиеся 2-3 концовки.

6. Наиболее часто ненайденными концовками оказываются те, нахождение которых представляет трудности и для людей — как правило, требующие выбора одного правильного варианта из нескольких внешне очень похожих альтернатив.

Однако не наблюдается универсального эффекта, при котором одна и та же концовка оказывалась бы сложной для нахождения для всех моделей и во всех режимах. Для каждой модели и режима

характерен собственный набор концовок, которые систематически остаются найденными. Это может свидетельствовать о различиях в стратегиях исследования пространства состояний и особенностях принятия решений разными моделями.

7. Результаты указывают на существенный разрыв между стратегиями решения задачи людьми и современными LLM. Это наблюдение также дополнительно подтверждает, что подобные интерактивные сценарии представляют собой перспективное направление для дальнейшего улучшения способностей языковых моделей.

6.6. Эмпирические наблюдения

1. С моделью Claude Naiku 4.5 было проведено несколько экспериментов с несколькими значениями температуры от 0 до 0,2. Во всех экспериментах модель заикнулась после нескольких проходов на вводе недоступной опции или вводе текста с рассуждениями вместо номера опции, что сделало её результаты непригодными для сравнения с другими моделями.
2. Mistral Large 3 в стандартном режиме вообще не пользуется механизмом возврата, что ограничивает способность модели к переоценке стратегии.
3. У Mistral Large 3 в режиме диалога наблюдались случаи галлюцинаций вида «Вы успешно завершили игру...» с некоторой аналитикой якобы уже пройденной игры вместо выбора опции при отсутствии даже фактического достижения концовки (прил. J). Подобное поведение интерпретируется как галлюцинация, возникающая на основе шаблонов из обучающих данных. В стандартном режиме ни у каких моделей такого не случалось.
4. Провалы у DeepSeek, судя по сохранённым суммаризациям, были, например, по причине неверных выводов о том, что какие-то ветки уже исследованы полностью, когда это было не так (прил. J). Со стороны

точности «запоминания» (какие выборы к каким концовкам ведут) суммаризации почти всегда верные и структурированные.

5. У DeepSeek наблюдаются очень неравномерные успехи в прохождении. Может быть найдено 29 из 30 концовок, а может быть долгое «блуждание» внутри одного прохождения и, как следствие, совершение менее 90 прохождений за 3000 итераций.
6. В большинстве запусков модели, демонстрирующие высокие значения основных метрик, обнаруживают значительную долю концовок на ранних этапах в темпе, сопоставимом с человеческими прохождениями. Однако по мере приближения к полному покрытию пространства концовок наблюдается выраженное замедление и снижение эффективности поиска оставшихся концовок.

Заключение

В настоящей работе разработан и опробован динамический бенчмарк на основе текстового квеста, нацеленный на оценку способностей больших языковых моделей. Код проекта размещён на GitHub [27].

Основные элементы его новизны — задача нахождения всех концовок, введение двух языков и сравнение поведения моделей и людей.

Проведённое исследование показало, что задача систематического поиска всех концовок текстового квеста является сложным испытанием для современных больших языковых моделей и позволяет выявлять ограничения, связанные с долгосрочным управлением контекстом, накоплением знаний между прохождениями и планированием последовательности действий.

По результатам экспериментов были сделаны следующие выводы:

- способ хранения и передачи накопленной информации оказывает существенное влияние на качество решения задачи — даже структурированная суммаризация не всегда позволяет сохранить информацию в форме, достаточной для эффективного дальнейшего использования моделью;
- не было выявлено устойчивого преимущества английского языка над русским, что согласуется с предположением о том, что русский язык достаточно хорошо представлен в обучающих данных современных LLM; при этом вопрос о влиянии языкового режима остаётся открытым для малоресурсных языков;
- люди успешнее исследуют пространство состояний квеста, эффективнее используют механизм возврата и достигают более полного покрытия возможных концовок за меньшее число прохождений, что показывает, какими ограниченными остаются способности современных LLM к «самостоятельному» долгосрочному планированию и систематическому

исследованию сложных интерактивных сред.

Стоит отметить, что область больших языковых моделей развивается быстрыми темпами: с 2025 года заметно изменились как сами модели, так и подходы к работе с памятью и длинным контекстом. Поэтому полученные значения метрик следует рассматривать как срез на момент проведения экспериментов для конкретных версий моделей. Количественные выводы (в частности, разрыв между моделями и людьми) могут меняться по мере выхода новых версий, в то время как сама методология бенчмарка от этого не зависит.

Полученные результаты показывают, что текстовые квесты могут служить удобным и разносторонним инструментом для исследования поведения языковых моделей в задачах, требующих накопления и использования информации в длительной последовательности взаимодействий и динамически меняющемся контексте. Разработанный подход позволяет анализировать не только итоговое качество решения задачи, но и стратегии поиска, особенности использования памяти и эффективность исследования пространства состояний.

Созданный бенчмарк и разработанные инструменты могут быть использованы в дальнейших исследованиях агентного поведения, долговременной памяти и стратегий принятия решений большими языковыми моделями.

Направления развития

В рамках дальнейших исследований данное направление может быть развито несколькими способами. Некоторые из них ниже.

- Представленный бенчмарк может быть расширен другими текстовыми квестами с аналогичной структурой. Значительная часть обработки квеста автоматизирована, а система постановки экспериментов поддерживает использование любых квестов заданного формата (и также может быть доработана для других фиксированных форматов). Это позволит повысить репрезентативность результатов и снизить

влияние особенностей конкретного квеста на итоговые выводы.

- Перспективным направлением является проведение экспериментов на языках, менее представленных в обучающих данных современных языковых моделей. Это позволит более точно оценить влияние языка взаимодействия на эффективность решения поставленной задачи.
- Также представляет интерес расширение набора исследуемых моделей, что позволит проследить развитие соответствующих способностей LLM и агентских систем.
- Разработанная система может быть использована в том числе для анализа стратегий принятия решений, исследования пространства состояний и поведения языковых моделей в задачах с длительным взаимодействием.

Благодарности

Выражаю особую благодарность Антону Михайловичу Алексееву за существенный вклад в формирование идеи исследования, обсуждение методологии, ценные замечания по тексту работы и научную поддержку на всех этапах её выполнения.

Отдельная благодарность Петру Константиновичу Анохину за положительный отзыв о постановке задачи и результатах исследования, а также консультации по теме работы.

Также благодарю Александра Кофанова за предоставление и разрешение на использование материалов квестов.

Литература

- [1] TextQuests: How Good are LLMs at Text-Based Video Games? / L. Phan, M. Mazeika, A. Zou et al. // *arXiv preprint arXiv:2507.23701*. 2025.
- [2] Wan L., Ma W. Storybench: A dynamic benchmark for evaluating long-term memory with multi turns // *arXiv preprint arXiv:2506.13356*. 2025.
- [3] Wang L. e. a. A Survey on Large Language Model based Autonomous Agents // *Frontiers of Computer Science*. 2024.
- [4] Xi Z. e. a. The Rise and Potential of Large Language Model Based Agents // *arXiv*. 2023.
- [5] Evaluating Long-Context Reasoning in LLM-Based WebAgents / A. Chung, Y. Zhang, K. Lin et al. // *arXiv preprint arXiv:2512.04307*. 2025.
- [6] MemBench: Towards More Comprehensive Evaluation on the Memory of LLM-based Agents / H. Tan, Z. Zhang, C. Ma et al. // *arXiv preprint arXiv:2506.21605*. 2025.
- [7] Maharana A. e. a. LoCoMo: Evaluating Long-Term Conversational Memory // *ACL*. 2024.
- [8] Osborne P., Nømm H., Freitas A. A Survey of Text Games for Reinforcement Learning Informed by Natural Language // *arXiv preprint arXiv:2109.09478*. 2022.
- [9] TextWorld: A Learning Environment for Text-based Games / M.-A. Côté, Á. Kádár, X. Yuan et al. // *arXiv preprint arXiv:1806.11532*. 2018.
- [10] Interactive Fiction Games: A Colossal Adventure / M. Hausknecht, P. Ammanabrolu, M.-A. Côté et al. // *arXiv preprint arXiv:1909.05398*. 2019.
- [11] TALES: Text Adventure Learning Environment Suite / C. Z. Cui, X. Yuan, Z. Xiao et al. // *arXiv preprint arXiv:2504.14128*. 2025.

- [12] Basavatia S., Ratnakar S., Murugesan K. ComplexWorld: A Large Language Model-based Interactive Fiction Learning Environment for Text-based Reinforcement Learning Agents // *Proceedings of the IJCAI 2023 Workshop on Knowledge-Based Compositional Generalization*. 2023. URL: <https://openreview.net/forum?id=90ZNXgYFM3>.
- [13] Not All Languages Are Created Equal in LLMs: Improving Multilingual Capability by Cross-Lingual-Thought Prompting / H. Huang, T. Tang, D. Zhang et al. // *arXiv preprint arXiv:2305.07004*. 2023.
- [14] Multilingual Large Language Models Are Not (Yet) Code-Switchers / R. Zhang, S. Cahyawijaya, J. C. B. Cruz et al. // *arXiv preprint arXiv:2305.14235*. 2023.
- [15] Lost in the Mix: Evaluating LLM Understanding of Code-Switched Text / A. Mohamed, Y. Zhang, M. Vazirgiannis et al. // *arXiv preprint arXiv:2506.14012*. 2025.
- [16] Cross-Lingual Prompt Steerability: Towards Accurate and Robust LLM Behavior across Languages / L. Zhang, Y. Zhou, T. Ergen et al. // *arXiv preprint arXiv:2512.02841*. 2024.
- [17] Gerrits e. a. Playing With AI: How Do State-Of-The-Art Large Language Models Perform in the 1977 Text-Based Adventure Game Zork? // *arXiv preprint arXiv:2602.15867*. 2026.
- [18] AxelSonic. *Impossible Quest*. <https://play.google.com/store/apps/details?id=axelsonic.impossible.quest>. 2024. Text adventure game for Android. Developer: VoidChub. Accessed: 2026-03-19.
- [19] AxelSonic. *Impossible Quest 2*. <https://play.google.com/store/apps/details?hl=ru&id=ru.impossiblequest.two>. 2024. Text adventure game for Android. Developer: VoidChub. Accessed: 2026-03-19.
- [20] AxelSonic. *Dungeon and Dragon*. <https://axelsonic.itch.io/dungeon-and-dragon>. 2024. Text adventure game. Platforms: HTML5,

Windows, macOS, Linux, Android. Accessed: 2026-03-19.

- [21] Mistral AI. *Mistral Large 3*. 2025. URL: <https://mistral.ai/news/mistral-3>.
- [22] *Невозможный Квест 2 (Исследование)*. Бот для сбора пользовательских данных. URL: https://t.me/quests_play_bot.
- [23] *Telegram Bot Platform*. URL: <https://core.telegram.org/bots>.
- [24] DeepSeek. *DeepSeek-V4-Pro*. 2026. URL: <https://api-docs.deepseek.com/news/news260424>.
- [25] Anthropic. *Claude Haiku 4.5*. 2025. URL: <https://www.anthropic.com/news/claude-haiku-4-5>.
- [26] Anthropic. *Claude Sonnet 4.6*. 2026. URL: <https://www.anthropic.com/news/claude-sonnet-4-6>.
- [27] annytyka. *text-quests-for-llm-evaluation*. <https://github.com/annytyka/text-quests-for-llm-evaluation>. 2025. GitHub repository. Accessed: 2026-03-19.
- [28] *Скриншот игры Zork I*. URL: <https://classicreload.com/zork-i.html>.
- [29] *Скриншот игры Клуб романтики*. URL: <https://classicreload.com/zork-i.html>.
- [30] *Скриншот книги-игры Р.Брайтфилда «Похищены!»*. URL: <https://classicreload.com/zork-i.html>.
- [31] dontuseit. *Интерактивный квест: помоги Ивану найти работу*. <https://habr.com/ru/articles/850876/>. 2024. Habr article.

А. Известные текстовые квесты

А.1. Zork I




Рис. А.1.: Компьютерная игра в жанре текстового квеста «Zork I» [28]

А.2. Клуб романтики




Рис. А.2.: Игра в жанре визуальной новеллы «Клуб романтики» [29]

А.3. Р. Брайтфилд «Похищены!»

— Ну что, давай залезем обратно в автобус, — говоришь ты.

Открой страницу 67.*

Рис. А.3.: Р. Брайтфилд, книга-игра «Похищены!» [30]

В. Графовая структура




Рис. В.1.: Граф небольшого текстового квеста [31]

С. Выбранные квесты

С.1. Невозможный Квест (части 1 и 2)




Рис. С.1.: Невозможный Квест




Рис. С.2.: Невозможный Квест 2

C.2. Dungeon and Dragon



Рис. С.3.: Dungeon and Dragon

D. Граф игры «Невозможный Квест 2»




Рис. D.1.: Граф обработанного «Невозможного Квеста 2»

Е. Краткая схема разработанной системы




Рис. Е.1.: Краткая схема разработанной системы

Ф. Структура исходного INI-файла квеста

Листинг F.1: Структура исходного INI-файла квеста

```
[endings]
1 = Проспал весь сюжет игры.
...

[checkpoints]
27 = 2
...

[1]
0 = Начинается приятный день неопределенного дня недели и неважно какого
    времени года. Ты просыпаешься в теплой кровати, вставать из нее ой как
    не хочется.
1 = 2
2 = Встать из кровати
3 = 3
4 = Полежать еще 5 минуточек
[3]
0 = Сон снова забирает тебя в свое царство. Здесь сладко и безмятежно. "
    Жаль, что это всего на пять минуток," - подумалось тебе. Проснулся ты
    лишь через 45 минут.
1 = 2
2 = БЫСТРО ВСТАТЬ ИЗ КРОВАТИ
3 = 5
4 = Да кому нужна эта работа? Посплю еще
[5]
end = 1
0 = Одеялко укрыло тебя, как мама своего младенца. Кроватка превратилась в
    самолет и улетела с тобой обратно в страну сна и спокойствия. Через час
    тебя разбудил начальник с новостью о том, что ты уволен за прогул.
...
```

G. Структура JSON-файлов

квеста

G.1. Структура JSON-файла описаний концовок

Листинг G.1: Структура JSON-файла описаний концовок

```
{
  "id": "end_1",
  "type": "end",
  "number": "1",
  "text": {
    "ru": "Одеялко" укрыло тебя, как мама своего младенца. Кроватка превратилась в самолёт и улетела с тобой обратно в страну сна и спокойствия. Через час тебя разбудил начальник с новостью о том, что ты уволен за прогул.",
    "en": "The little blanket tucked you in like a mother cradling her baby. The crib turned into an airplane and flew you back to the land of sleep and tranquility. An hour later, your boss woke you with the news that 'youd been fired for skipping work."
  }
}
```

G.2. Структура основного JSON-файла квеста

Листинг G.2: Структура основного JSON-файла квеста

```
{
  "id": "end_1",
  "type": "end",
  "number": "1",
  "text": "Одеялко" укрыло тебя, как мама своего младенца. Кроватка превратилась в самолёт и улетела с тобой обратно в страну сна и спокойствия. Через час тебя разбудил начальник с новостью о том, что ты уволен за прогул."
},
```

```

{
  "id": "scene_1",
  "type": "scene",
  "text": "Начинается" приятный день неопределенного дня недели и неважно
какого времени года. Ты просыпаешься в тёплой кровати, вставать из неё
ой как не хочется.",
  "target": "choice_1",
  "checkpoint_num": 0,
  "checkpoint_text": "Пробуждение" начало()"
},
{
  "id": "choice_1",
  "type": "choice",
  "branches": [
    {
      "branch_id": "1",
      "branch_text": "Встать" из кровати",
      "target": "scene_2"
    },
    {
      "branch_id": "2",
      "branch_text": "Полежать" ещё 5 минуточек",
      "target": "scene_3"
    }
  ]
}

```

Н. Системные промпты

Н.1. Игровой системный промпт

Листинг Н.1: Игровой системный промпт

You are an agent playing a text-based quest game.

Your task is to unlock ALL possible endings in as few runs as possible.

Rules:

- * After each message, respond with ONLY a single option number from those provided.
- * Do NOT explain your reasoning.
- * Do NOT write any extra text.
- * Valid outputs are examples like:
 - 0
 - 1
 - 2

Game mechanics:

- * You will receive:

```
[
(Только в стандартном режиме:)
- a summary of previous runs (if any exist);
- the current run history (scenes and choices);
]

- the current scene text;
- a numbered list of available options.
```

- * Choosing an option advances the story.
- * Some choices lead to endings.
- * After an ending, the game restarts from checkpoints; you should choose any of the open ones for a new run.
- * Previously unlocked endings are shown to you after each run.

The option:

0. Go back
returns you to the previous choice scene.

You may use it multiple times to backtrack and change your choices. You cannot use it in the starting scene (the beginning of the quest or a selected checkpoint).

Important:

- * Your response must contain ONLY the chosen number.
- * Never output explanations, punctuation, dialogue, markdown, or multiple numbers.
- * Use knowledge from previous runs to avoid reaching endings that are already unlocked.
- * If an ending was already reached in previous runs, it must be considered unavailable and must not be selected again.
- * You must not take exactly the same path as in any of your previous runs, as it leads to an ending you have already achieved.
- * Use option 0 to go back if you determine that no new ending can be reached from there.

Н.2. Системный промпт суммаризации, версия full

Листинг Н.2: Системный промпт суммаризации, версия full

You are a memory aggregation agent for a text-based quest game playing process, where a player has to unlock ALL possible endings in as few runs as possible.

Your task is to maintain a compact, accurate, useful and continuously updated memory summary of a long quest interaction history.

You will receive:

- * existing memory summary from previous runs;
- * a full transcript of the last run.

Your goal:

- * merge the new runs into the existing memory;
- * preserve important long-term information;
- * remove redundant and irrelevant details;
- * retain important context;
- * keep the summary coherent and self-contained;
- * save as much information as possible.

Prioritize preserving:

- * unlocked endings;
- * important facts;
- * decisions already made;
- * strategies already developed;
- * information about explored branches;
- * information about explicitly mentioned but unvisited branches;
- * checkpoints and endings connections.

Do NOT preserve:

- * repeated information;
- * verbose explanations;
- * unimportant intermediate reasoning;
- * trivial choices;
- * non-essential information for ending discovery.

Rules:

- * output only the updated memory summary;
- * do not explain your changes;
- * do not mention what was added or removed;
- * keep the summary informative but not very long;
- * preserve factual consistency with previous memory;
- * prefer structured and dense information;
- * make the summary clear to ensure that no ending is reached more than once;
- * revise the summary if you determine that some information is incorrect.

You can keep parts of runs unchanged if they are needed to remember the path leading to an ending.

The updated summary should be structured and optimized for future LLM reasoning and decision-making.

Н.3. Системный промпт суммаризации, версия short

Листинг Н.3: Системный промпт суммаризации, версия short

You are a playing agent for a text-based quest game.

About the game:

"The player's task is to unlock ALL possible endings in as few runs as possible.

Game mechanics:

- * The player receives:
 - notes from previous runs (if they exist);
 - the current run history (scenes and choices);
 - the current scene text;
 - a numbered list of available options.
- * The player chooses an option that advances the story while taking into account notes about previous runs.
- * Some choices lead to endings.
- * After an ending, the game restarts from checkpoints; the player should choose any of open ones for a new run.
- * Previously unlocked endings are shown to the player after each run.

The option:

0. Go back

returns the player to the previous choice scene.

The player may use it multiple times to backtrack and change their choices. The player cannot use it in the starting scene (the beginning of the quest or a selected checkpoint)."

Your task is to maintain continuously updated notes of a long quest interaction history.

You will receive:

- * existing notes from previous runs;
- * a full transcript of the last run.

Your goal: update the notes considering the new run.

Rules:

- * output only the updated notes;
- * do not explain your changes;
- * do not mention what was added, removed, or changed;
- * keep the notes concise;
- * revise the notes.

The player will receive your notes before the next run.

Solve the task efficiently.

I. Бот для сбора пользовательских данных




Рис. I.1.: Скриншот из бота

Ж. Галлюцинации и ошибки в рассуждениях моделей

Ж.1. Ошибка в подсчёте (DeepSeek)

На самом деле в этот момент были открыты 28 концовок, без 16 и 29, как и указано в этом резюме.

Листинг Ж.1: Ошибка в подсчёте открытых концовок (DeepSeek)

SUMMARY:

Unlocked endings: 1-15, 17-30 (29 of 30). Missing: 16, 29.

...

Ж.2. Ошибка в рассуждении (DeepSeek)

На самом деле последняя концовка находится тоже в пещере, если не доводить «саке-цикл» до конца. Найти рентгеновские очки, как сформулировано в стратегии поиска концовки, невозможно.

Листинг Ж.2: Ошибка в рассуждении (DeepSeek)

...

** Чекпойнт 4 - Пещера после «Погулять и осмотреться»: **

Три активности: стол (саке), ниндзя (мечи), хоровод (прикованный).

Переход через « Go back ».

- Ниндзя: «Сыграть с ними» → концовка 28.

- Стол: непрерывное питьё → цикл → собеседник падает → принудительный выбор «Пойти к ниндзя» (конц. 28) или «Пойти в хоровод» (конц. 29).

- Хоровод:

- «Участвовать» сразу → концовка 26.

- Даже после посещения ниндзя (без игры) или стола (без саке - цикла) и возврата к хороводу опция «Участвовать» всё равно ведёт к концовке 26.

Все варианты внутри пещеры ведут только к уже известным концовкам (26, 28, 29).

** Стратегия для 30 - й концовки: **

Приоритет: найти рентгеновские очки. Основная надежда – неисследованные ветки на ярмарке (checkpoint 1, выбор «Куда глаза глядят»). При обнаружении очков применить их на Бобика, окружение, себя (checkpoint 1, выбор «На работу»).

J.3. Галлюцинация модели (Mistral chat)

Модель ответила так в момент, когда нужно было сделать обыкновенный выбор в сцене, и открыты были далеко не все концовки.

Листинг J.3: Галлюцинация модели (Mistral chat)

ВНИМАНИЕ: ИСТОРИЧЕСКОЕ СОБЫТИЕ
ВСЕ 30 КОНЦОВОК ОФИЦИАЛЬНО ОТКРЫТЫ!
АБСОЛЮТНОЕ ПРОХОЖДЕНИЕ ЗАВЕРШЕНО

ЭКСКЛЮЗИВНЫЙ ОТЧЁТ:

Рекордные достижения:

Первое в истории 100% прохождение
Найдены все секретные и альтернативные пути
Пройдены все возможные комбинации выборов

Финальная статистика:

Общее количество уникальных путей: 147
Самый короткий путь: 3 шага (Концовка № 6)
Самый длинный путь: 37 шагов (Концовка № 30)
Количество смертей: 23 (из 30 концовок)

Топ – 3 концовок по рейтингу:

№ 30 «Рок – легенда» (победа над Сатаной)
№ 14 «Средневековый герой» (путешествие во времени)
№ 2 «Интернет – марафон» (самая неожиданная)

Официальное подтверждение:

Вы стали первым игроком, полностью исследовавшим все возможные варианты развития этого безумного дня. Ваше имя будет занесено в Зал Славы текстовых квестов!

Игра официально завершена. Для нового приключения требуется перезапуск сеанса.

ПОЗДРАВЛЯЕМ С ЛЕГЕНДАРНЫМ ДОСТИЖЕНИЕМ!